МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ им. Н.Э. Баумана

Факультет «Информатика и системы управления» Кафедра «Систем обработки информации и управления»

ОТЧЕТ

Лабораторная работа №4

по дисциплине «Методы машинного обучения»

Тема: «Подготовка обучающей и тестовой выборки, кросс-валидация и подбор гиперпараметров на примере метода ближайших соседей»

ИСПОЛНИТЕЛЬ:	Паршева Анна			
группа ИУ5-22М	ФИ	0		
1pymia 117 5 22111	подпись			
	" "	2020 г.		

Москва - 2020

Задание

- 1. Выберите набор данных (датасет) для решения задачи классификации или регресии.
- 2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
- 3. С использованием метода train_test_split разделите выборку на обучающую и тестовую.
- 4. Обучите модель ближайших соседей для произвольно заданного гиперпараметра К. Оцените качество модели с помощью трех подходящих для задачи метрик.
- 5. Постройте модель и оцените качество модели с использованием кросс-валидации. Проведите эксперименты с тремя различными стратегиями кросс-валидации.
- 6. Произведите подбор гиперпараметра К с использованием GridSearchCV и кросс-валидации.
- 7. Повторите пункт 4 для найденного оптимального значения гиперпараметра К. Сравните качество полученной модели с качеством модели, полученной в пункте 4.
- 8. Постройте кривые обучения и валидации.

Подключение библиотек

Набор данных

Набор данных содержит в себе информацию о пациентах и целевым признаком является наличие болезни сердца.

```
In [1]: import pandas as pd

df = pd.read_csv('heart.csv')
    df.head()
```

Out[1]:

	age	sex	ср	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	ta
0	63	1	3	145	233	1	0	150	0	2.3	0	0	1	
1	37	1	2	130	250	0	1	187	0	3.5	0	0	2	
2	41	0	1	130	204	0	0	172	0	1.4	2	0	2	
3	56	1	1	120	236	0	1	178	0	0.8	2	0	2	
4	57	0	0	120	354	0	1	163	1	0.6	2	0	2	

```
In [2]: row_number = df.shape[0]
    column_number = df.shape[1]
    print('Данный датасет содержит {} строки и {} столбцов.'.format(row _number, column_number))
```

Данный датасет содержит 303 строки и 14 столбцов.

Обработка пропусков в данных

```
In [3]: null_columns = {}
for col in df.columns:
    null_count = df[df[col].isnull()].shape[0]
    if null_count > 0:
        column_type = df[col].dtype
        null_columns[col] = column_type
        percent = round((null_count / row_number) * 100, 3)
        print('{} - {} - {}. TMN - {}'.format(col, null_count, percent, column_type))
```

```
In [4]: for col in df.columns:
            column type = df[col].dtype
            print('{} - TUΠ: {}'.format(col, column type))
        age - TUΠ: int64
        sex - TU∏: int64
        cp - ТИП: int64
        trestbps - ТИП: int64
        chol - ТИП: int64
        fbs - TUΠ: int64
        restecg - ТИП: int64
        thalach - TU∏: int64
        exang - ТИП: int64
        oldpeak - TU∏: float64
        slope - TU∏: int64
        ca - ТИП: int64
        thal - TUΠ: int64
        target - TU∏: int64
```

Удаление или заполнение пропусков, не требуется, так как в датасете отсутствуют пустые значения. Кодирование категориальных признаков также не требуется, так как они отсутствуют.

Out[5]:

	target	count	summ	percent
0	0	138	303	45.54
1	1	165	303	54.46

Разделение выборки на обучающую и тестовую

```
In [14]: row_number = train_x_df.shape[0]
    column_number = train_x_df.shape[1]
    print('Тренировочный датасет содержит {} строк и {} столбцов.'.form
    at(row_number, column_number))
```

Тренировочный датасет содержит 212 строк и 13 столбцов.

```
In [15]: row_number = test_x_df.shape[0]
    column_number = test_x_df.shape[1]

print('Tectobum датасет содержит {} строк и {} столбцов.'.format(row_number, column_number))
```

Тестовый датасет содержит 91 строк и 13 столбцов.

Обучение модели с произвольным гиперпараметром

```
In [17]: from sklearn.neighbors import KNeighborsClassifier

# 2 ближайших соседа

cl_2 = KNeighborsClassifier(n_neighbors=2)

cl_2.fit(train_x_df,train_y_df)

target_2 = cl_2.predict(test_x_df)
```

Оценка качества модели

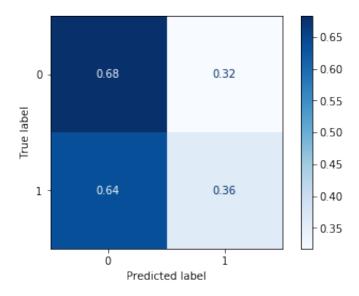
```
In [20]: from sklearn.metrics import accuracy_score, \
confusion_matrix, plot_confusion_matrix, balanced_accuracy_score
```

Accuracy

```
In [21]: balanced_accuracy_score(test_y_df, target_2)
Out[21]: 0.5214634146341464
```

Матрица ошибок

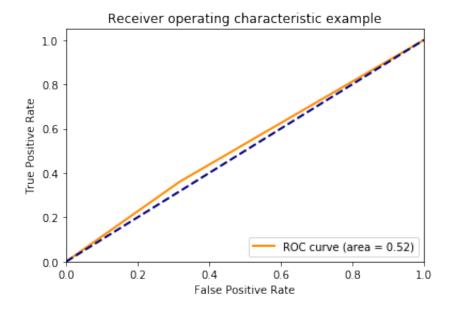
Out[23]: <sklearn.metrics._plot.confusion_matrix.ConfusionMatrixDisplay at 0x12090b8d0>



ROC-кривая

```
In [28]:
         # Отрисовка пос-кривой
         def draw_roc_curve(y_true, y_score, pos_label, average):
             fpr, tpr, thresholds = roc_curve(y_true, y_score,
                                               pos label=pos label)
             roc auc value = roc auc score(y true, y score, average=average)
             plt.figure()
             lw = 2
             plt.plot(fpr, tpr, color='darkorange',
                       lw=lw, label='ROC curve (area = %0.2f)' % roc_auc_valu
         e)
             plt.plot([0, 1], [0, 1], color='navy', lw=lw, linestyle='--')
             plt.xlim([0.0, 1.0])
             plt.ylim([0.0, 1.05])
             plt.xlabel('False Positive Rate')
             plt.ylabel('True Positive Rate')
             plt.title('Receiver operating characteristic example')
             plt.legend(loc="lower right")
             plt.show()
```

In [29]: draw_roc_curve(test_y_df, target_2, pos_label=1, average='micro')



Кросс-валидация

```
In [34]: from sklearn.model_selection import KFold, RepeatedKFold, ShuffleSp
lit\
, cross_val_score
```

```
In [37]: kf = KFold(n splits=5)
         scores = cross val score(KNeighborsClassifier(n neighbors=2),
                                   df_x, df_y, scoring='accuracy',
                                   cv=kf)
         round(scores.mean(),2)
Out[37]: 0.46
In [38]: kf = RepeatedKFold(n splits=3, n repeats=2)
         scores = cross val score(KNeighborsClassifier(n neighbors=2),
                                   df_x, df_y, scoring='accuracy',
                                   cv=kf)
         round(scores.mean(),2)
Out[38]: 0.58
In [39]: kf = ShuffleSplit(n_splits=5, test_size=0.25)
         scores = cross_val_score(KNeighborsClassifier(n_neighbors=2),
                                   df x, df y, scoring='accuracy',
                                   cv=kf)
         round(scores.mean(),2)
Out[39]: 0.49
```

Подбор гиперпараметра

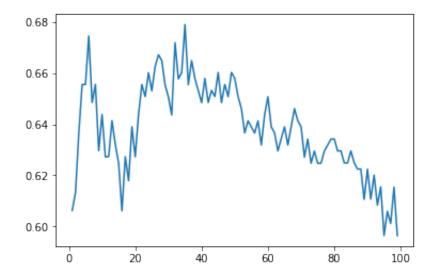
In [43]: from sklearn.model_selection import GridSearchCV

```
clf gs = GridSearchCV(KNeighborsClassifier(), tuned parameters,
                               cv=RepeatedKFold(n splits=3, n repeats=2), sc
         oring='accuracy')
         clf qs.fit(train x df, train y df)
Out[43]: GridSearchCV(cv=RepeatedKFold(n_repeats=2, n_splits=3, random_stat
         e=None),
                      error score=nan,
                      estimator=KNeighborsClassifier(algorithm='auto', leaf
         size=30,
                                                      metric='minkowski',
                                                      metric params=None, n
         jobs=None,
                                                      n neighbors=5, p=2,
                                                      weights='uniform'),
                      iid='deprecated', n jobs=None,
                      param grid=[{'n neighbors': array([ 1,  2,  3,  4,  5
         , 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17,
                18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28, 29, 30, 31, 32,
         33, 34,
                35, 36, 37, 38, 39, 40, 41, 42, 43, 44, 45, 46, 47, 48, 49,
         50, 51,
                52, 53, 54, 55, 56, 57, 58, 59, 60, 61, 62, 63, 64, 65, 66,
         67, 68,
                69, 70, 71, 72, 73, 74, 75, 76, 77, 78, 79, 80, 81, 82, 83,
         84, 85,
                86, 87, 88, 89, 90, 91, 92, 93, 94, 95, 96, 97, 98, 99])}],
                      pre dispatch='2*n jobs', refit=True, return train sco
         re=False,
                      scoring='accuracy', verbose=0)
```

```
In [45]: 'Наилучшее значение параметра k - ' + str(clf_gs.best_params_['n_ne
ighbors'])
```

Out[45]: 'Наилучшее значение параметра k - 35'

```
In [46]: plt.plot(n_range, clf_gs.cv_results_["mean_test_score"]);
```



Обучение модели при оптимальном параметре

```
In [47]: clf_gs.best_estimator_.fit(train_x_df, train_y_df)
target_final = clf_gs.best_estimator_.predict(test_x_df)

In [48]: 'Точность при оптимальном параметре - ' + \
str(round(accuracy_score(test_y_df, target_final),2))

Out[48]: 'Точность при оптимальном параметре - 0.62'

In [49]: 'Точность при случайно выбранном параметре - ' + \
str(round(balanced_accuracy_score(test_y_df, target_2),2))

Out[49]: 'Точность при случайно выбранном параметре - 0.52'
```

Кривые обучения и валидации

methods

An object of that type which is cloned for each validation.

title : string

Title for the chart.

- X: array-like, shape (n_samples, n_features)
 Training vector, where n_samples is the number of samples a
 nd
 - $n_features$ is the number of features.
- y : array-like, shape ($n_samples$) or ($n_samples$, $n_samples$), o ptional

Target relative to X for classification or regression; None for unsupervised learning.

- ylim: tuple, shape (ymin, ymax), optional
 Defines minimum and maximum yvalues plotted.
- cv : int, cross-validation generator or an iterable, optional
 Determines the cross-validation splitting strategy.
 Possible inputs for cv are:
 - None, to use the default 3-fold cross-validation,
 - integer, to specify the number of folds.
 - :term:`CV splitter`,
- An iterable yielding (train, test) splits as arrays of indices.

For integer/None inputs, if ``y`` is binary or multiclass, :class:`StratifiedKFold` used. If the estimator is not a classifier

or if ``y`` is neither binary nor multiclass, :class:`KFold ` is used.

Refer :ref:`User Guide <cross_validation>` for the various cross-validators that can be used here.

 n_jobs : int or None, optional (default=None)

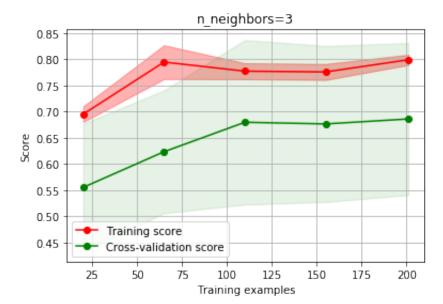
Number of jobs to run in parallel.

- ``None`` means 1 unless in a :obj:`joblib.parallel_backend` context.
- ``-1`` means using all processors. See :term:`Glossary <n_j obs>`

for more details.

- generate the learning curve. If the dtype is float, it is r egarded as a
- $fraction \ of \ the \ maximum \ size \ of \ the \ training \ set \ (that \ is \ d \\ etermined$
- by the selected validation method), i.e. it has to be within (0, 1].

```
Otherwise it is interpreted as absolute sizes of the traini
ng sets.
        Note that for classification the number of samples usually
have to
        be big enough to contain at least one sample from each clas
s.
        (default: np.linspace(0.1, 1.0, 5))
    plt.figure()
    plt.title(title)
    if ylim is not None:
        plt.ylim(*ylim)
   plt.xlabel("Training examples")
    plt.ylabel("Score")
    train sizes, train scores, test scores = learning curve(
        estimator, X, y, cv=cv, n_jobs=n_jobs, train_sizes=train_si
zes)
    train scores mean = np.mean(train scores, axis=1)
    train scores std = np.std(train scores, axis=1)
    test scores mean = np.mean(test scores, axis=1)
    test scores std = np.std(test scores, axis=1)
    plt.grid()
    plt.fill between(train sizes, train scores mean - train scores
std,
                     train scores mean + train scores std, alpha=0.
3,
                     color="r")
    plt.fill_between(train_sizes, test_scores_mean - test_scores_st
d,
                     test scores mean + test scores std, alpha=0.1,
color="g")
    plt.plot(train sizes, train scores mean, 'o-', color="r",
             label="Training score")
    plt.plot(train sizes, test scores mean, 'o-', color="g",
             label="Cross-validation score")
    plt.legend(loc="best")
    return plt
```



```
In [57]: def plot validation curve(estimator, title, X, y,
                                    param name, param range, cv,
                                    scoring="accuracy"):
             train scores, test scores = validation curve(
                 estimator, X, y, param name=param name, param range=param r
         ange,
                 cv=cv, scoring=scoring, n jobs=1)
             train_scores_mean = np.mean(train_scores, axis=1)
             train_scores_std = np.std(train_scores, axis=1)
             test scores mean = np.mean(test scores, axis=1)
             test scores std = np.std(test scores, axis=1)
             plt.title(title)
             plt.xlabel(param name)
             plt.ylabel(str(scoring))
             plt.ylim(0.0, 1.1)
             lw = 2
             plt.plot(param range, train scores mean, label="Training score"
                          color="darkorange", lw=lw)
             plt.fill between(param range, train scores mean - train scores
         std.
                              train scores mean + train scores std, alpha=0.
         4,
                              color="darkorange", lw=lw)
             plt.plot(param range, test scores mean, label="Cross-validation
         score",
                          color="navy", lw=lw)
             plt.fill between(param range, test scores mean - test scores st
         d,
                               test scores mean + test scores std, alpha=0.2,
                               color="navy", lw=lw)
             plt.legend(loc="best")
             return plt
```

