МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
им. Н.Э. Баумана

Факультет «Информатика и системы управления»
Кафедра «Систем обработки информации и управления»

ОТЧЕТ

Лабораторная работа №5
по дисциплине «Методы машинного обучения»

Тема: «Линейные модели, SVM и деревья решений»

ИСПОЛНИТЕЛЬ: __Паршева Анна____
ФИО
группа ИУ5-22М _____
подпись
"__"_____2020 г.

Москва - 2020

1. Задание

- Выберите набор данных (датасет) для решения задачи классификации или регрессии.
- В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
- С использованием метода train_test_split разделите выборку на обучающую и тестовую.
- Обучите следующие модели: одну из линейных моделей; SVM; дерево решений.
- Оцените качество моделей с помощью трех подходящих для задачи метрик. Сравните качество полученных моделей.
- Произведите для каждой модели подбор одного гиперпараметра с использованием GridSearchCV и кросс-валидации.
- Повторите пункт 4 для найденных оптимальных значений гиперпараметров. Сравните качество полученных моделей с качеством моделей, полученных в пункте 4.

2. Подготовка данных

Выбранный набор данных представляет из себя набор характеристик различных автомобилей, целевой переменной является - цена автомобиля

In [12]:
```
import pandas as pd

df = pd.read_csv('CarPrice.csv')
df.head()
```

Out[12]:

	car_ID	symboling	CarName	fueltype	aspiration	doornumber	carbody	drivewheel
0	1	3	alfa-romero giulia	gas	std	two	convertible	rwd
1	2	3	alfa-romero stelvio	gas	std	two	convertible	rwd
2	3	1	alfa-romero Quadrifoglio	gas	std	two	hatchback	rwd
3	4	2	audi 100 ls	gas	std	four	sedan	fwd
4	5	2	audi 100ls	gas	std	four	sedan	4wd

5 rows × 26 columns

In [14]:
```
row_number = df.shape[0]
column_number = df.shape[1]

print('Данный датасет содержит {} строк и {} столбцов.'.format(row_
number, column_number))
```

```
Данный датасет содержит 205 строк и 26 столбцов.
```

In [15]:
```
null_flag = False
null_columns = {}
for col in df.columns:
    null_count = df[df[col].isnull()].shape[0]
    if null_count > 0:
        null_flag = True
        column_type = df[col].dtype
        null_columns[col] = column_type
        percent = round((null_count / row_number) * 100, 3)
        print('{} - {} - {}. Тип - {}'.format(col, null_count, perc
ent, column_type))

if not null_flag:
    print('Пропуски в данных отсутствуют.')
```

```
Пропуски в данных отсутствуют.
```

In [17]:
```
for col in df.columns:
    column_type = df[col].dtype
    if column_type == 'object':
        print(col)
```

```
CarName
fueltype
aspiration
doornumber
carbody
drivewheel
enginelocation
enginetype
cylindernumber
fuelsystem
```

In [18]:
```
from sklearn.preprocessing import LabelEncoder

le = LabelEncoder()

for col in df.columns:
    df[col] = le.fit_transform(df[col])
```

In [19]:
```
for col in df.columns:
    column_type = df[col].dtype
    if column_type == 'object':
        print(col)
```

In [73]:
```
from sklearn.model_selection import train_test_split

df_x = df.loc[:, df.columns != 'price']
df_y = df['price']
train_x_df, test_x_df, train_y_df, test_y_df = train_test_split(df_
x,df_y,
                                                test_size=0.3, random_state=1)
```

In [43]:
```
row_number_train = train_x_df.shape[0]
column_number_train = train_x_df.shape[1]

print('Тренировочный датасет содержит {} строки и {} столбцов.'.for
mat(row_number_train, column_number_train))
```

```
Тренировочный датасет содержит 143 строки и 25 столбцов.
```

In [42]:
```
row_number_test = test_x_df.shape[0]
column_number_test = test_x_df.shape[1]

print('Тестовый датасет содержит {} строки и {} столбцов.'.format(r
ow_number_test, column_number_test))
```

```
Тестовый датасет содержит 62 строки и 25 столбцов.
```

3. Обучение моделей

3.1 Линейная модель

3.1.1 Матрица корреляции

In [38]:
```
corr_matrix = df.corr()
corr_matrix
```

Out[38]:

	car_ID	symboling	CarName	fueltype	aspiration	doornumber	ca
car_ID	1.000000	-0.151621	0.967077	-0.125568	0.067729	-0.190352	0.0
symboling	-0.151621	1.000000	-0.107095	0.194311	-0.059866	0.664073	-0.5
CarName	0.967077	-0.107095	1.000000	-0.069435	0.019914	-0.171745	0.0
fueltype	-0.125568	0.194311	-0.069435	1.000000	-0.401397	0.191491	-0.1
aspiration	0.067729	-0.059866	0.019914	-0.401397	1.000000	-0.031792	0.0
doornumber	-0.190352	0.664073	-0.171745	0.191491	-0.031792	1.000000	-0.6
carbody	0.098303	-0.596135	0.099691	-0.147853	0.063028	-0.680358	1.0
drivewheel	0.051406	-0.041671	-0.016129	-0.132257	0.066465	0.098954	-0.1
enginelocation	0.051483	0.212471	0.055968	0.040070	-0.057191	0.137757	-0.2
wheelbase	0.162792	-0.535721	0.051429	-0.296072	0.246290	-0.466657	0.4
carlength	0.162165	-0.357163	0.051896	-0.196281	0.244096	-0.382903	0.3
carwidth	0.104421	-0.234801	-0.010630	-0.231914	0.311695	-0.229790	0.1
carheight	0.255711	-0.516952	0.194678	-0.299030	0.121833	-0.550000	0.5
curbweight	0.119667	-0.208850	0.007118	-0.201092	0.345925	-0.211981	0.1
enginetype	-0.075130	0.050372	-0.090381	0.082695	-0.102963	0.062431	-0.0
cylindernumber	-0.040912	0.197762	0.047154	0.110617	-0.133119	0.154322	-0.0
enginesize	0.028107	-0.102395	-0.090497	-0.126387	0.197266	-0.036787	-0.0
fuelsystem	0.204898	0.091163	0.123845	0.041529	0.288086	0.015519	-0.0
boreratio	0.271661	-0.129044	0.201561	-0.043657	0.210910	-0.117787	0.0
stroke	-0.175206	-0.018198	-0.205093	-0.302867	0.223521	0.004591	-0.0
compressionratio	0.175895	-0.053801	0.168305	-0.634479	-0.143321	-0.058337	0.0
horsepower	-0.003477	0.054142	-0.095958	0.160982	0.307844	0.092022	-0.1
peakrpm	-0.217333	0.275404	-0.149881	0.487600	-0.181173	0.239094	-0.1
citympg	0.033055	-0.049180	0.111351	-0.257728	-0.204284	-0.005580	0.0
highwaympg	0.022503	0.019534	0.116787	-0.173238	-0.264490	0.021068	-0.0
price	0.012452	-0.089579	-0.096100	-0.140119	0.307676	-0.115160	0.0

26 rows × 26 columns

In [37]:
```
corr_matrix['price'].nlargest(4)
```

Out[37]:
```
price          1.000000
curbweight     0.905891
horsepower     0.846130
enginesize     0.818392
Name: price, dtype: float64
```

In [27]:
```
import seaborn as sns

sns.set(rc={'figure.figsize':(11.7,8.27)})
sns.heatmap(corr_matrix)
```

Out[27]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x1229205c0>
```

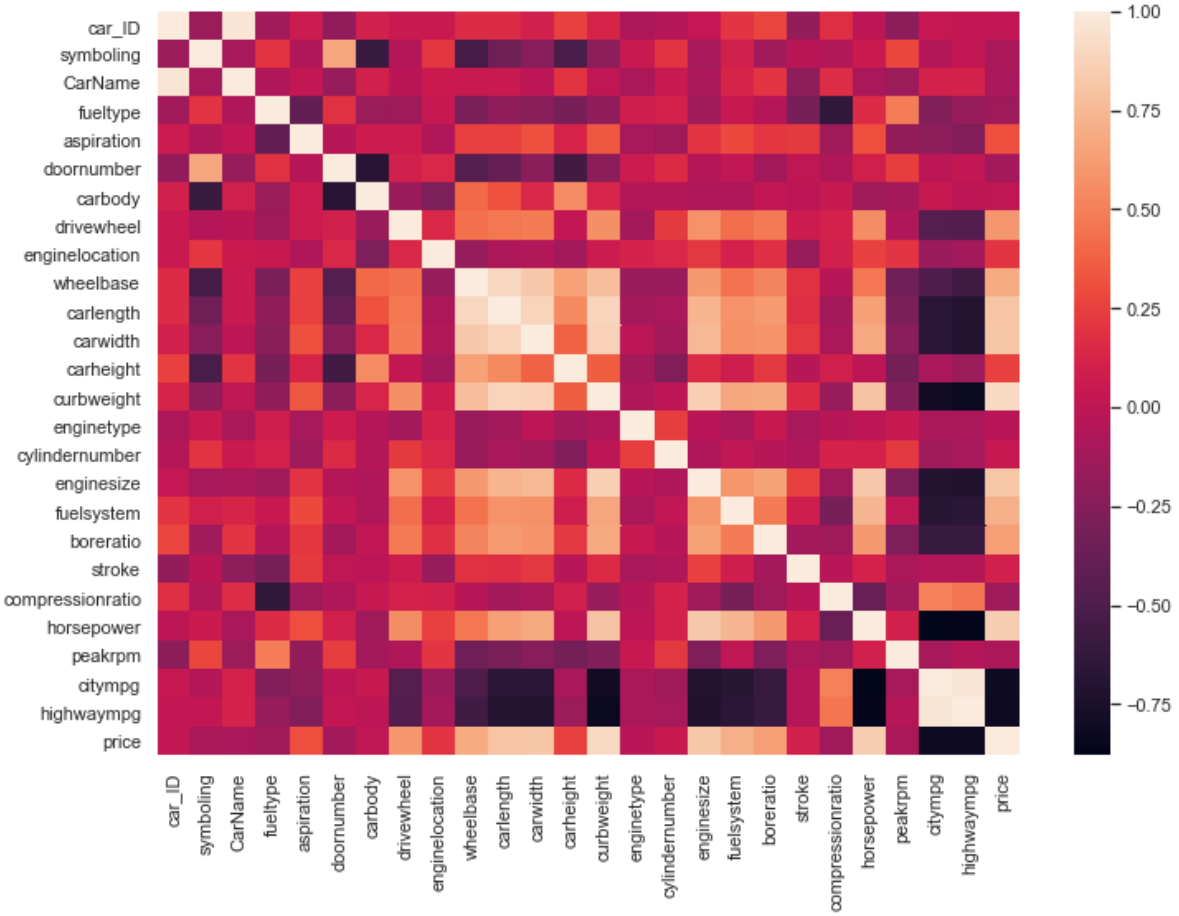

In [32]:
```
import plotly.express as px
fig = px.scatter(df, x='price', y='curbweight')
fig.show()
```

In [33]:
```
fig = px.scatter(df, x='price', y='horsepower')
fig.show()
```

In [39]:
```
fig = px.scatter(df, x='price', y='enginesize')
fig.show()
```

3.1.2 Вычисление коэффициентов регрессии матричным способом

$$B = \left(X^T X\right)^{-1} X^T Y$$

In [40]:
```
import numpy as np
```

In [110]:
```
X_0 = np.ones(row_number_train).T
X = np.column_stack((X_0, train_x_df))
B = np.dot(np.dot(np.linalg.inv(np.dot(X.T,X)),X.T),train_y_df)
B
```

Out[110]:
```
array([ 5.24106398e+01, -1.02311681e-01,  2.18470564e+00, -2.11642
101e-02,
       -2.92692816e+01, -5.83570818e+00, -7.93128553e+00, -4.40863
223e+00,
        2.52699519e+00,  3.20434750e+01,  6.34225165e-01, -2.06578
965e-01,
        7.36209558e-01,  2.50456405e-01,  3.60955023e-01,  9.91672
740e-01,
        4.48711749e-01, -4.77936652e-01,  3.58618089e+00, -2.09333
506e-01,
       -5.03714418e-01,  5.71833312e-01,  1.43046552e+00, -1.12281
838e-01,
       -2.40925647e+00,  1.50738855e+00])
```

3.1.3 Использование класса LinearRegression библиотеки scikit-learn

3.1.3.1 Обучение с произвольным гиперпараметром

In [194]:
```
from sklearn.linear_model import Lasso
reg1 = Lasso(alpha=0.1).fit(np.array(train_x_df),
                            np.array(train_y_df).reshape(-1, 1))
B_1 = (reg1.intercept_, reg1.coef_)
```

In [195]:
```
B_1
```

Out[195]:
```
(array([42.14887115]),
 array([-1.11567509e-01,  1.84913331e+00, -1.05906495e-02, -2.0189
2043e+01,
        -6.63162812e-01, -7.31529743e+00, -4.77816533e+00,  1.8302
3531e+00,
         2.38949769e+01,  6.35998365e-01, -2.13153098e-01,  6.5925
4648e-01,
         2.64508407e-01,  3.75002489e-01,  9.35438073e-01,  4.1329
2452e-01,
        -2.53813867e-01,  3.67533788e+00, -1.76396306e-01, -4.9812
8698e-01,
         8.44526642e-01,  1.25702856e+00, -1.09337548e-02, -2.5537
7484e+00,
         1.55622583e+00]))
```

3.1.3.2 Оценка качества модели

In [196]:
```
predicted_y_reg = reg1.predict(np.array(test_x_df))
```

In [197]:
```
predict_test_df = pd.DataFrame(test_y_df)
predict_test_df['predicted_y'] = predicted_y
```

In [198]:
```
import plotly.graph_objects as go

fig = go.Figure()
fig.add_trace(go.Scatter(x=np.arange(predict_test_df['predicted_y']
.shape[0]),
                         y=predict_test_df['predicted_y'],
                         name='predicted'
             ))

fig.add_trace(go.Scatter(x=np.arange(predict_test_df['predicted_y']
.shape[0]),
                         y=predict_test_df['price'],
                         name='test'
                        ))

fig.show()
```

In [212]:
```
from sklearn.metrics import r2_score, mean_absolute_error

r2_reg = round(r2_score(test_y_df, predicted_y_reg), 2)
mae_reg = round(mean_absolute_error(test_y_df, predicted_y_reg), 2)

print('Коэффициент детерминации - %.2f' % r2_reg)
print('Средняя абсолютная ошибка - %.2f' % mae_reg)
```

```
Коэффициент детерминации - 0.88
Средняя абсолютная ошибка - 14.93
```

3.1.3.3 Подбор гиперпараметра

In [209]:
```
from sklearn.model_selection import GridSearchCV
from sklearn.model_selection import RepeatedKFold

n_range = np.arange(0.1, 1.2, 0.1)
tuned_parameters = [{'alpha': n_range}]

gs = GridSearchCV(Lasso(),
                  param_grid=tuned_parameters,
                  cv=RepeatedKFold(n_splits=3, n_repeats=2),
                  scoring='r2')
gs.fit(train_x_df, train_y_df)
```

Out[209]:
```
GridSearchCV(cv=RepeatedKFold(n_repeats=2, n_splits=3, random_stat
e=None),
             error_score=nan,
             estimator=Lasso(alpha=1.0, copy_X=True, fit_intercept
=True,
                             max_iter=1000, normalize=False, posit
ive=False,
                             precompute=False, random_state=None,
                             selection='cyclic', tol=0.0001, warm_
start=False),
             iid='deprecated', n_jobs=None,
             param_grid=[{'alpha': array([0.1, 0.2, 0.3, 0.4, 0.5,
0.6, 0.7, 0.8, 0.9, 1. , 1.1])}],
             pre_dispatch='2*n_jobs', refit=True, return_train_sco
re=False,
             scoring='r2', verbose=0)
```

3.1.3.4 Обучение с наилучшим гиперпараметром

In [210]:
```
gs.best_estimator_.fit(train_x_df, train_y_df)
predicted_y_best_reg = gs.best_estimator_.predict(test_x_df)
```

In [211]:
```
r2_reg_best = round(r2_score(test_y_df, predicted_y_best_reg), 2)

print('Коэффициент детерминации при случайном гиперпараметре - %.2f
'
      % r2_reg)
print('Коэффициент детерминации при наилучшем гиперпараметре - %.2f
'
      % r2_reg_best)
```

```
Коэффициент детерминации при случайном гиперпараметре - 0.88
Коэффициент детерминации при наилучшем гиперпараметре - 0.89
```

3.2 SVM

3.2.1 Обучение с произвольным гиперпараметром

In [156]:
```
from sklearn.svm import SVR

svr = SVR(kernel='linear', C=100)

svr.fit(train_x_df, train_y_df)

predicted_y_svr = svr.predict(test_x_df)
```

3.2.2 Оценка качества модели

In [162]:
```
r2 = round(r2_score(test_y_df, predicted_y_svr), 2)

print('Коэффициент детерминации - %.2f' % r2)
```

```
Коэффициент детерминации - 0.87
```

3.2.3 Подбор гиперпараметра

In [158]:
```
from sklearn.model_selection import GridSearchCV
from sklearn.model_selection import RepeatedKFold

n_range = np.arange(0.1,1,0.1)
tuned_parameters = [{'C': n_range}]

gs = GridSearchCV(SVR(kernel='linear'),
                  param_grid=tuned_parameters,
                  cv=RepeatedKFold(n_splits=3, n_repeats=2),
                  scoring='r2')
gs.fit(train_x_df, train_y_df)
```

Out[158]:
```
GridSearchCV(cv=RepeatedKFold(n_repeats=2, n_splits=3, random_stat
e=None),
             error_score=nan,
             estimator=SVR(C=1.0, cache_size=200, coef0=0.0, degre
e=3,
                           epsilon=0.1, gamma='scale', kernel='lin
ear',
                           max_iter=-1, shrinking=True, tol=0.001,
                           verbose=False),
             iid='deprecated', n_jobs=None,
             param_grid=[{'C': array([0.1, 0.2, 0.3, 0.4, 0.5, 0.6
, 0.7, 0.8, 0.9])}],
             pre_dispatch='2*n_jobs', refit=True, return_train_sco
re=False,
             scoring='r2', verbose=0)
```

In [159]:
```
'Наилучшее значение параметра c - ' + str(gs.best_params_['C'])
```

Out[159]:
```
'Наилучшее значение параметра c - 0.9'
```

3.2.4 Обучение с наилучшим гиперпараметром

In [160]:
```
gs.best_estimator_.fit(train_x_df, train_y_df)
predicted_y_best_svr = gs.best_estimator_.predict(test_x_df)
```

In [164]:
```
r2_best = round(r2_score(test_y_df, predicted_y_best_svr), 2)

print('Коэффициент детерминации при случайном гиперпараметре - %.2f
' % r2)
print('Коэффициент детерминации при наилучшем гиперпараметре - %.2f
' % r2_best)
```

```
Коэффициент детерминации при случайном гиперпараметре - 0.87
Коэффициент детерминации при наилучшем гиперпараметре - 0.88
```

3.3 Дерево решений

3.3.1 Обучение с произвольным гиперпараметром

In [166]:
```
from sklearn.tree import DecisionTreeRegressor

dtr = DecisionTreeRegressor(random_state=1).fit(train_x_df,
                                                train_y_df)
predict_y_dtr = dtr.predict(test_x_df)
```

3.3.2 Оценка качества модели

In [167]:
```
r2_dtr = round(r2_score(test_y_df, predict_y_dtr), 2)

print('Коэффициент детерминации при случайном гиперпараметре - %.2f
' % r2_dtr)
```

```
Коэффициент детерминации при случайном гиперпараметре - 0.80
```

3.3.3 Подбор гиперпараметра

In [168]:
```
params = {
    'max_depth': [3, 4, 5, 6],
    'min_samples_leaf': [0.04, 0.06, 0.08],
    'max_features': [0.2, 0.4, 0.6, 0.8]
}

grid = GridSearchCV(estimator=DecisionTreeRegressor(random_state=1)
,
                    param_grid=params, scoring='r2', cv=3, n_jobs=-
1)

grid.fit(train_x_df, train_y_df)
```

Out[168]:
```
GridSearchCV(cv=3, error_score=nan,
             estimator=DecisionTreeRegressor(ccp_alpha=0.0, criter
ion='mse',
                                             max_depth=None, max_f
eatures=None,
                                             max_leaf_nodes=None,
                                             min_impurity_decrease
=0.0,
                                             min_impurity_split=No
ne,
                                             min_samples_leaf=1,
                                             min_samples_split=2,
                                             min_weight_fraction_l
eaf=0.0,
                                             presort='deprecated',
                                             random_state=1, split
ter='best'),
             iid='deprecated', n_jobs=-1,
             param_grid={'max_depth': [3, 4, 5, 6],
                         'max_features': [0.2, 0.4, 0.6, 0.8],
                         'min_samples_leaf': [0.04, 0.06, 0.08]},
             pre_dispatch='2*n_jobs', refit=True, return_train_sco
re=False,
             scoring='r2', verbose=0)
```

In [170]:
```
for param in params.keys():
    print('Наилучшее значение параметра %s - ' % param + str(grid.b
est_params_[param]))
```

```
Наилучшее значение параметра max_depth - 6
Наилучшее значение параметра min_samples_leaf - 0.04
Наилучшее значение параметра max_features - 0.2
```

3.2.4 Обучение с наилучшим гиперпараметром

In [171]:
```
grid.best_estimator_.fit(train_x_df, train_y_df)
predicted_y_best_dtr = grid.best_estimator_.predict(test_x_df)
```

In [172]:
```
r2_best_dtr = round(r2_score(test_y_df, predicted_y_best_svr), 2)

print('Коэффициент детерминации при случайном гиперпараметре - %.2f
' %
      r2_dtr)
print('Коэффициент детерминации при наилучшем гиперпараметре - %.2f
' %
      r2_best_dtr)
```

```
Коэффициент детерминации при случайном гиперпараметре - 0.80
Коэффициент детерминации при наилучшем гиперпараметре - 0.88
```

3.2.5 Наиболее важные признаки

In [220]:
```
test_df = pd.DataFrame(list(zip(train_x_df.columns,
          grid.best_estimator_.feature_importances_)))

fig = px.bar(test_df, x=0, y=1)
fig.show()
```

3.2.6 Визуализация дерева

In [225]:
```
from sklearn.tree.export import export_text
from sklearn.tree import export_graphviz
import graphviz
import pydotplus

# Визуализация дерева
def get_png_tree(tree_model_param, feature_names_param):
    dot_data = StringIO()
    export_graphviz(tree_model_param, out_file=dot_data, feature_na
mes=feature_names_param,
                    filled=True, rounded=True, special_characters=T
rue)
    graph = pydotplus.graph_from_dot_data(dot_data.getvalue())
    return graph.create_png()
```

In [231]:
```
from IPython.display import Image
from sklearn.externals.six import StringIO
Image(get_png_tree(grid.best_estimator_, train_x_df.columns), heigh
t="500")
```

Out[231]: